

Soutenabilité économique des agents conversationnels pédagogiques : une étude de cas sur le coût par token dans un dispositif d'apprentissage des langues assisté par IA générative

WORKING PAPER — TECHNOLOGIE ÉDUCATIVE / DIGITAL LEARNING

Loïc Berthod *Expert en pédagogie numérique (digital pedagogy), consultant indépendant* lberthod@gmail.com · info@loicberthod.ch

1^{er} août 2026

Déclaration d'intérêts

L'auteur est le concepteur et éditeur indépendant du dispositif étudié (application Leggend). Le terrain d'étude est donc également son propre produit, ce qui constitue un conflit d'intérêts potentiel à déclarer explicitement : l'auteur a un intérêt direct à présenter le dispositif de façon favorable. Pour en limiter l'effet sur la validité des résultats, cette étude ne porte pas sur l'évaluation de la qualité pédagogique du dispositif (non mesurée ici), mais sur des indicateurs techniques objectifs — volumes de tokens facturés, directement lus dans les réponses de l'API du fournisseur, reproductibles indépendamment de l'auteur. Aucun financement externe n'a été sollicité pour ce travail.

Résumé structuré

Contexte. Les agents conversationnels fondés sur des grands modèles de langage (LLM) sont de plus en plus intégrés aux dispositifs d'apprentissage des langues assisté par ordinateur (*Computer-Assisted Language Learning*, CALL), en particulier pour la pratique de l'interaction simulée. À la différence d'un interlocuteur humain, un agent conversationnel a un coût marginal mesurable par tour de parole, facturé par le fournisseur du modèle au volume de texte échangé (le *token*).

Objectif. Documenter, sur un dispositif réel en production, l'existence et l'ampleur d'un gaspillage évitable de ce coût marginal, et déterminer par quel mécanisme il peut être réduit sans dégrader la production observable du système.

Méthode. Étude de cas expérimentale sur le module de dialogue simulé de l'application Leggend (apprentissage de l'italien pour un public francophone, modèle DeepSeek `deepseek-v4-flash`). Protocole de comparaison directe (A/B) contre l'infrastructure de produc-

tion réelle pour chaque hypothèse d'optimisation testée, avec mesure des indicateurs objectifs renvoyés par l'API (tokens d'entrée, de sortie, tokens servis depuis le cache, tokens attribuables au raisonnement interne du modèle).

Résultats. L'hypothèse initiale — un gain provenant de la mise en cache du contexte conversationnel — n'est confirmée qu'à la marge (taux de cache quasi inchangé, 88,5 % → 87,2 %). Le facteur de coût dominant, identifié a posteriori, est un mécanisme de raisonnement interne (*chain-of-thought*) activé par défaut par le fournisseur, représentant jusqu'à 74,7 % à 85 % des tokens de sortie facturés sans production de contenu visible par l'apprenant. Sa désactivation ciblée, combinée à des ajustements mineurs, réduit le coût mesuré d'environ 70 % par session sans dégradation qualitative observée.

Conclusion. Le poste de coût déterminant d'un agent conversationnel pédagogique n'est pas nécessairement celui que suggère l'architecture apparente du système. Une évaluation de la soutenabilité économique, fondée sur la mesure empirique plutôt que sur l'intuition, devrait faire partie intégrante de la conception de tout dispositif de dialogue simulé destiné à un déploiement à grande échelle.

Abstract (EN). LLM-based conversational agents are increasingly used in Computer-Assisted Language Learning (CALL) for simulated dialogic practice. Unlike a human interlocutor, such agents carry a measurable marginal cost per turn, billed by the model provider per token. This case study documents, on a production language-learning dialogue feature (Leggendo, Italian for French speakers, DeepSeek `deepseek-v4-flash`), an empirically-driven cost optimization achieving an approximate 70 % reduction per session. Contrary to the initial hypothesis (context caching), the dominant cost factor was found to be the model's default internal reasoning process, accounting for up to 85 % of billed output tokens without producing learner-visible value. The study argues that economic sustainability assessment should be a standard component of designing generative-AI-based learning tools intended for scale.

Mots-clés : technologie éducative, digital learning, apprentissage des langues assisté par ordinateur (CALL), agents conversationnels, IA générative, soutenabilité économique, passage à l'échelle (*scalability*)

Keywords: educational technology, digital learning, computer-assisted language learning (CALL), conversational agents, generative AI, economic sustainability, scalability

1. Introduction et problématique

1.1 La pratique dialoguée comme levier pédagogique

La didactique des langues secondes accorde une place centrale à l'interaction : produire du langage en situation, recevoir une réponse contingente, ajuster sa formulation — un cycle que la recherche en acquisition des langues associe à un apprentissage plus robuste que l'exposition passive seule

(Long, 1996 ; Swain, 1985). Reproduire ce cycle en dehors de la salle de classe s'est longtemps heurté à une contrainte simple : il faut un interlocuteur disponible. Les agents conversationnels fondés sur des LLM lèvent en grande partie cette contrainte, en simulant un interlocuteur toujours disponible, adaptable au niveau de l'apprenant, et capable de tenir un rôle contextualisé (un barista, un médecin, un guichetier) — une évolution que la littérature récente en CALL commence à documenter (Godwin-Jones, 2022, sur l'intégration des IA génératives dans l'enseignement des langues).

1.2 Une contrainte nouvelle : le coût marginal du dialogue simulé

Ce que la littérature pédagogique aborde peu, en revanche, est la **contrainte économique** propre à ce type de dispositif. Un dialogue avec un tuteur humain n'a pas de coût marginal facturé au tour de parole ; un dialogue avec un agent LLM en a un, car chaque échange déclenche un appel à une API tierce facturée au volume de texte traité. Un dispositif pédagogique qui fonctionne en laboratoire ou en pilote restreint peut ainsi devenir non soutenable économiquement lorsqu'il est déployé à l'échelle d'un établissement ou d'une plateforme grand public — une préoccupation typique du champ du *digital learning*, où la littérature identifie régulièrement le passage à l'échelle (*scalability*), plus que la pertinence pédagogique elle-même, comme le facteur limitant la pérennité des dispositifs numériques innovants.

C'est cette question — *le coût d'un agent conversationnel pédagogique est-il compressible sans perte de qualité perçue par l'apprenant, et dans quelle mesure ?* — que cette étude de cas examine sur un dispositif réel en production.

1.3 Terrain d'étude

Le dispositif étudié est le module de dialogue simulé de Leggendo, application d'apprentissage de l'italien pour un public francophone. Cinq scénarios de la vie quotidienne (café, cabinet médical, gare, marché, hôtel) permettent à l'apprenant de jouer une scène face à un personnage tenu par un modèle de langage (DeepSeek, modèle `deepseek-v4-flash`), calibré sur le niveau CECR déclaré (A1 à B1 selon le scénario). Une session comporte une ouverture de scène, jusqu'à douze tours de dialogue, et un bilan pédagogique final relevant les erreurs de l'apprenant — soit jusqu'à quatorze appels au modèle par session, pour un forfait de crédits fixe côté utilisateur, indépendant du nombre de tours effectivement joués.

2. Hypothèse de recherche

L'hypothèse formulée en amont de l'expérimentation portait sur la **mise en cache du contexte conversationnel**, mécanisme par lequel un fournisseur d'API peut facturer à un tarif réduit les segments de texte déjà rencontrés récemment dans une requête antérieure :

L'implémentation initiale reconstruit l'historique de la conversation en un seul bloc de texte à chaque tour, avec un formatage qui varie légèrement d'un appel à l'autre. Cette

instabilité du texte empêche le mécanisme de cache de reconnaître un préfixe déjà traité. Structurer l'historique en messages distincts et stables devrait rétablir la correspondance de préfixe et réduire fortement le coût facturé.

Cette hypothèse était cohérente avec le fonctionnement documenté des architectures de cache par préfixe et constituait, a priori, le levier d'optimisation le plus prometteur.

3. Méthodologie

Conformément à une démarche expérimentale plutôt que déductive, chaque hypothèse a été testée par comparaison directe (protocole A/B) contre l'infrastructure de production réelle, et non simplement déduite de la documentation du fournisseur :

1. formulation d'une hypothèse précise et réfutable ;
2. implémentation isolée de la modification testée ;
3. exécution d'une conversation identique (même scénario, même niveau, mêmes répliques d'apprenant) sous les deux conditions (avant / après) ;
4. relevé des indicateurs objectifs renvoyés par l'API (tokens d'entrée, de sortie, tokens servis depuis le cache, tokens attribuables au raisonnement interne du modèle) ;
5. décision fondée sur la mesure, non sur la plausibilité théorique de l'hypothèse.

Cette démarche empirique a permis, comme développé ci-dessous, d'identifier un résultat contraire à l'hypothèse initiale — ce qui n'aurait pas été détecté par une analyse purement théorique de l'architecture du système.

Validité et reproductibilité. Les mesures rapportées proviennent directement du champ `usage` des réponses de l'API du fournisseur (tokens d'entrée, de sortie, tokens en cache, tokens de raisonnement), et non d'une estimation dérivée. Le protocole (même scénario, même niveau, mêmes répliques d'apprenant, conditions expérimentales alternées) est documenté intégralement dans le code source du dispositif étudié, ce qui en permet la réplication.

4. Résultats

4.1 Réfutation partielle de l'hypothèse initiale

La comparaison A/B sur une conversation de trois tours donne :

Condition	Tokens d'entrée	Tokens servis depuis le cache	Taux de cache
Avant (historique en texte aplati)	2602	2304	88,5 %
Après (historique structuré)	2349	2048	87,2 %

Le taux de réutilisation du cache reste, dans les faits, quasiment identique entre les deux conditions : l'hypothèse initiale — un gain substantiel attendu du seul fait de structurer l'historique — n'est pas confirmée. Le mécanisme de cache du fournisseur s'est révélé plus tolérant au bruit de formatage que ne le laissait supposer sa documentation générale.

Cette étape expérimentale n'a cependant pas été sans valeur : elle a permis d'identifier un **défaut fonctionnel** non lié au coût — un format de réponse structurée (JSON) qui échouait silencieusement dès lors que l'historique de conversation contenait des tours antérieurs ne respectant pas exactement le schéma attendu par le modèle. Ce défaut, corrigé au passage, aurait pu se traduire en production par des dialogues interrompus sans cause apparente pour l'apprenant.

4.2 Le facteur de coût réel : le raisonnement interne du modèle

L'examen détaillé des tokens de sortie a révélé que la majorité du coût ne provenait pas de la réponse visible par l'apprenant, mais d'un mécanisme de *raisonnement en chaîne* (« *chain-of-thought* ») que le modèle exécute par défaut avant de produire sa réponse finale — un processus interne, non affiché à l'utilisateur, mais intégralement facturé :

Condition	Tokens de sortie (3 tours)	Dont raisonnement invisible
Réglage par défaut	953	712 (74,7 %)
Raisonnement désactivé	163	0

Un test complémentaire sur le module de bilan pédagogique (repérage d'erreurs grammaticales dans les productions de l'apprenant) a par ailleurs montré qu'un réglage intermédiaire (effort de raisonnement réduit plutôt que supprimé) ne produisait pas de réduction proportionnée du coût, ni de gain de qualité :

Réglage	Tokens de sortie	Dont raisonnement	Corrections identifiées
Effort réduit	896	764 (85 %)	1
Raisonnement désactivé	147	0	2

Pour ce type de tâche — production contrainte et courte, relevant davantage de la performance langagière que du raisonnement multi-étapes — la suppression complète du mécanisme de raisonnement s'est révélée à la fois moins coûteuse et qualitativement au moins équivalente, sinon supérieure.

4.3 Gains complémentaires

Un allègement du texte d'instruction système (mêmes consignes pédagogiques, formulation resserrée d'environ 35 %) a réduit de 24 % le coût du premier appel de chaque session — le seul moment où ce texte n'est pas déjà disponible en cache pour les sessions ultérieures du même scénario.

5. Discussion : implications pour la conception de dispositifs numériques d'apprentissage

Trois enseignements dépassent le cas technique étudié et intéressent plus largement la conception de dispositifs de *digital learning* fondés sur l'IA générative :

(1) Le coût pédagogique invisible n'est pas toujours là où on l'attend. Le poste de dépense dominant (le raisonnement interne du modèle) n'était ni documenté de façon proéminente, ni intuitif au moment de la conception initiale du dispositif. Un concepteur pédagogique ou un décideur institutionnel évaluant le coût d'un agent conversationnel sur la seule base de la longueur du texte échangé sous-estimerait ce facteur de façon significative — un facteur qui, ici, représentait à lui seul les trois quarts du coût de sortie.

(2) Les fonctions conversationnelles courtes n'exigent pas les mêmes réglages qu'une tâche de raisonnement. La distinction, dans la conception d'un agent pédagogique, entre les interactions relevant de la *performance langagière contrainte* (jouer un rôle, produire une réplique courte et calibrée sur un niveau) et celles relevant du *raisonnement* (résoudre un problème, expliquer une règle complexe) a une traduction technique directe et un impact économique mesurable. Un même modèle, utilisé avec les mêmes réglages sur ces deux types de tâches, ne produit pas un usage économiquement efficient sur les deux à la fois.

(3) La soutenabilité économique conditionne le passage à l'échelle pédagogique. Un dispositif validé pédagogiquement sur un petit groupe d'apprenants ne garantit pas sa viabilité budgétaire lorsqu'il est déployé à l'échelle d'un établissement ou d'une plateforme grand public. La section suivante quantifie cette question sur un scénario de déploiement à 1000 apprenants.

6. Portée à l'échelle : scénario à 1000 apprenants

6.1 Coût par session

En prenant pour base une session type de six tours d'apprenant (valeur médiane, le maximum autorisé par le dispositif étant de douze), et une grille tarifaire indicative du fournisseur (non vérifiée sur facturation réelle, valeurs d'ordre de grandeur usuelles pour ce type de service : ~ 0,10 \$ / million de tokens d'entrée, ~ 1,10 \$ / million de tokens de sortie) :

coût avant optimisation	≈ 0,0041 \$ par session
coût après optimisation	≈ 0,0012 \$ par session
rabais	≈ 71 %

6.2 Scénario institutionnel : 1000 apprenants, 5 sessions/mois chacun

Hypothèse de charge compatible avec le forfait mensuel proposé aux utilisateurs premium (30 crédits/mois, 2 crédits par session, soit un plafond théorique de 15 sessions/mois — 5 sessions retenues ici comme estimation d'usage réel, plus prudente que le plafond) :

	Coût mensuel estimé	Coût annuel estimé
Sans optimisation	≈ 20,55 \$	≈ 246,60 \$
Avec optimisation	≈ 5,95 \$	≈ 71,40 \$
Économie	≈ 14,60 \$ / mois	≈ 175,20 \$ / an

6.3 Effet de l'échelle

Le rabais relatif (≈ 71 %) est indépendant de la taille de la cohorte ; seul le montant absolu croît avec elle :

Effectif d'apprenants actifs	Sessions/mois estimées	Coût mensuel sans optimisation	Coût mensuel avec optimisation	Économie/mois
1 000	5 000	20,55 \$	5,95 \$	14,60 \$
10 000	50 000	205,50 \$	59,50 \$	146,00 \$
50 000	250 000	1 027,50 \$	297,50 \$	730,00 \$

À l'échelle d'un pilote restreint (1000 apprenants), l'enjeu économique reste modeste en valeur absolue. Il devient un poste réel du budget d'infrastructure pédagogique numérique dès lors que le dispositif s'inscrit dans une logique de passage à l'échelle propre au *digital learning* institutionnel — déploiement multi-établissements, intégration à une plateforme nationale ou usage renforcé au-delà du forfait initial (jusqu'à trois fois plus de sessions par apprenant que l'hypothèse retenue ici).

7. Limites de l'étude

- **Conflit d'intérêts** (voir Déclaration d'intérêts, p. 1) : le terrain étudié est le propre produit de l'auteur, ce qui justifie le choix méthodologique de ne rapporter que des indicateurs techniques objectifs, et non une évaluation de la qualité pédagogique perçue.
- Les tarifs utilisés pour les projections monétaires sont **indicatifs**, non confirmés par une facturation réelle du fournisseur pour le modèle concerné ; seules les mesures en volume de tokens (avant/après) sont directement vérifiées et fiables.
- L'échantillon expérimental reste limité : un scénario, un niveau CECR, une conversation de trois tours testée en comparaison directe. La généralisation à une session de six tours (§6.1) repose sur une interpolation, non sur une mesure directe de bout en bout.
- La stabilité du mécanisme de cache du fournisseur dans le temps n'est pas documentée avec précision et pourrait varier selon la fréquence réelle de sollicitation d'un même scénario par des apprenants différents.
- Cette étude documente un effet de coût, non un effet d'apprentissage : la suppression du raisonnement interne du modèle n'a été évaluée que sur des critères de forme (contenu produit, cohérence du personnage), pas au moyen d'une mesure contrôlée des acquis linguistiques des

apprenants — une limite qu'une recherche ultérieure en didactique pourrait combler par une évaluation comparative des apprentissages selon la configuration du modèle.

8. Conclusion et perspectives

Cette étude de cas illustre un phénomène qui dépasse le seul dispositif examiné : dans la conception d'un agent conversationnel pédagogique, le poste de coût le plus significatif n'est pas nécessairement celui que l'intuition ou la documentation du fournisseur mettent en avant. Seule une démarche de test empirique systématique, mesurant chaque hypothèse contre le système réel plutôt que de s'appuyer sur son architecture supposée, a permis d'identifier le levier réellement efficace — la désactivation d'un mécanisme de raisonnement sans valeur pédagogique ajoutée sur ce type de tâche — plutôt que le levier initialement pressenti.

Pour la recherche et la pratique en technologie éducative, cette étude suggère qu'une évaluation de la **soutenabilité économique** devrait faire partie intégrante de la conception de tout dispositif d'apprentissage fondé sur l'IA générative destiné à un déploiement à grande échelle, au même titre que son évaluation pédagogique. Des travaux ultérieurs pourraient utilement croiser cette dimension économique avec une mesure des acquis d'apprentissage, afin de déterminer si des réglages de modèle optimisés pour le coût préservent, dégradent, ou améliorent l'efficacité pédagogique perçue et mesurée des dispositifs de dialogue simulé.

Références

Godwin-Jones, R. (2022). Partnering with AI: Intelligent writing assistance and instructed language learning. *Language Learning & Technology*.

Long, M. H. (1996). The role of the linguistic environment in second language acquisition. In W. Ritchie & T. Bhatia (Eds.), *Handbook of Second Language Acquisition*. Academic Press.

Swain, M. (1985). Communicative competence: Some roles of comprehensible input and comprehensible output in its development. In S. Gass & C. Madden (Eds.), *Input in Second Language Acquisition*. Newbury House.

Note biographique

Loïc Berthod est consultant indépendant en pédagogie numérique (*digital pedagogy*), concepteur d'outils d'apprentissage des langues assistés par IA. Contact : lberthod@gmail.com · info@loicberthod.ch